朴素贝叶斯模型：
从有限多值特征推广到干豆分类

颜千淞　SUAT25000446

深圳理工大学

概率论与数理统计探究项目

摘要

朴素贝叶斯通过类条件独立性将高维联合分布分解为一维分布的乘积，从而降低参数估计的难度。本文将二值模型推广到有限多值特征与多类别情形，推导最大后验判别、极大似然估计及基于 Dirichlet 先验的拉普拉斯平滑，并在 UCI Dry Bean 数据集上完成分类实验。使用给定的三水平离散特征时，9526 条与 1000 条训练样本所得模型的测试准确率分别为 83.87% 与 83.40%。全量模型高出 0.47 个百分点，配对 McNemar 精确检验 $p = 0.0127$，表明差异可被统计检出，但实际幅度有限。将条件概率替换为条件密度后，高斯与核密度朴素贝叶斯的准确率分别为 89.84% 与 90.04%。类内相关性、重复特征与删除特征实验说明，条件独立性在本数据中不成立；分类决策对部分冗余具有一定稳健性，但概率输出存在明显过度自信。进一步以训练集五折分层交叉验证选择标准化的 RBF 核支持向量分类器，采用 27 个特征、$C = 10$ 与 $\gamma =$ `scale`，测试准确率达到 93.29%，较离散基准提高 9.42 个百分点。实验说明，保留连续信息与选择更灵活的判别模型均有助于改善结果，同时应区分统计显著性、实际效应大小及探索性分析的局限。

关键词：朴素贝叶斯；条件独立性；拉普拉斯平滑；干豆分类；支持向量机

目录

1 引言

贝叶斯决策以给定观测后的类别后验概率为依据。在 0–1 损失下，选择后验概率最大的类别可以最小化条件错误率。然而，从有限样本估计高维联合分布通常十分困难。朴素贝叶斯以类条件独立性作为结构约束，将这一问题分解为若干一维分布的估计，在计算效率与模型表达能力之间取得折中。

本文依据课程任务书 [**?**]，从课堂中的二值情形出发，讨论有限多值特征与多类别的一般模型，并将其用于干豆品种识别。Dry Bean 数据集包含 13611 个样本、16 个形状测量特征及 7 个类别，特征之间存在明显相关关系，适合考察离散化、样本量与独立性假设的影响 [**?**, **?**]。

全文依次回答四组问题：第一，如何推导一般形式的朴素贝叶斯及其平滑估计；第二，1000 条与 9526 条训练样本所得模型的分类效果有何差异；第三，如何处理连续特征，以及相关特征会如何影响预测类别与概率；第四，在固定测试划分下，如何通过预处理与模型选择改善分类结果。

实验以项目提供的数据、代码及保存结果为基础。本文在整理时重新核对了数据划分、分箱边界、离散与高斯模型的主要结果，并独立复核最终支持向量机的五折交叉验证与测试准确率。复核脚本及新增统计量见附录**??**。本文保留原始实验记录，补充区分实测事实、解释性推断与尚未验证的机制。

2 有限多值特征与多类别的朴素贝叶斯

2.1 记号与贝叶斯决策

设训练数据为 $\mathcal{D} = \{(\boldsymbol{x}^{(n)}, y^{(n)})\}_{n=1}^{N}$，其中 $\boldsymbol{x}^{(n)} = (x_1^{(n)}, \dots, x_m^{(n)})$。随机变量 X_i 的取值集合为 $\mathcal{X}_i = \{x_{i,1}, \dots, x_{i,k_i}\}$，类别 Y 的取值集合为 $\mathcal{Y} = \{y_1, \dots, y_k\}$。记

$$\pi_c = P(Y = y_c), \qquad \theta_{c,i,j} = P(X_i = x_{i,j} \mid Y = y_c). \tag{2.1}$$

训练集中类别 c 的样本数为 N_c；类别为 c 且特征 i 取值为 $x_{i,j}$ 的样本数为 $N_{c,i,j}$。对待分类样本 $\boldsymbol{x}$，用 $j_i(\boldsymbol{x})$ 表示其第 i 个特征的取值索引，即 $x_i = x_{i,j_i(\boldsymbol{x})}$，避免将数值本身与表格下标混用。

由贝叶斯公式，对边缘概率非零的观测有

$$P(Y = y_c \mid \boldsymbol{X} = \boldsymbol{x}) = \frac{\pi_c P(\boldsymbol{X} = \boldsymbol{x} \mid Y = y_c)}{\sum_{a=1}^{k} \pi_a P(\boldsymbol{X} = \boldsymbol{x} \mid Y = y_a)}. \tag{2.2}$$

若误分类的损失为 1、正确分类的损失为 0，则将 $\boldsymbol{x}$ 判为 y_c 的条件风险为 $R(c \mid \boldsymbol{x}) = 1 - P(Y = y_c \mid \boldsymbol{X} = \boldsymbol{x})$。因此最优规则为最大后验决策：

$$\hat{c}(\boldsymbol{x}) = \arg\max_{c=1,\dots,k} \pi_c P(\boldsymbol{X} = \boldsymbol{x} \mid Y = y_c), \qquad \hat{y}(\boldsymbol{x}) = y_{\hat{c}(\boldsymbol{x})}. \tag{2.3}$$

分母与候选类别无关，故不影响排序；若先验相等，则该规则等价于最大化类条件似然。

2.2 直接估计联合分布的维数灾难

一般离散联合分布共有 $K = \prod_{i=1}^{m} k_i$ 个可能状态，每个类别需估计 $K - 1$ 个自由参数。若同时估计类别先验，总参数量为

$$p_{\text{joint}} = (k - 1) + k\left(\prod_{i=1}^{m} k_i - 1\right). \tag{2.4}$$

本项目 $m = 16$、$k_i = 3$、$k = 7$，故 $K = 3^{16} = 43046721$，条件分布部分已有 301327040 个自由参数，计入先验共 301327046 个。9526 条训练样本平均分摊到 kK 个类别与状态组合中，仅约为

$9526/(7\times 3^{16}) = 3.16\times 10^{-5}$ 条/格；即使忽略类别区分，平均每个特征状态也仅有 2.21×10^{-4} 条观测。

困难首先是统计上的稀疏性：绝大多数联合状态无样本支持，无法可靠估计其概率。其次是存储与计算开销：按双精度数保存约 3.0×10^{8} 个概率需约 2.4 GB，且开销随 m 指数增长。贝叶斯公式本身并未失效；产生维数灾难的是在缺乏结构约束时估计高维联合分布。

表 1 两种模型的自由参数量（均计入 $k-1=6$ 个先验参数）

特征数 m	联合状态数 3^m	一般联合模型	朴素贝叶斯
2	9	62	34
4	81	566	62
8	6561	45926	118
12	531441	3720086	174
16	43046721	301327046	230

2.3 条件独立性与判别函数

朴素贝叶斯假设：给定类别后，全部特征相互条件独立，即对任意类别 c 与取值组合，

$$P(\boldsymbol{X}=\boldsymbol{x}\mid Y=y_c)=\prod_{i=1}^{m}P(X_i=x_i\mid Y=y_c)=\prod_{i=1}^{m}\theta_{c,i,j_i(\boldsymbol{x})}. \tag{2.5}$$

这里需要相互条件独立，单独的两两条件独立一般不足以推出乘积分解。该假设不要求特征同分布，也不要求它们在总体上边缘独立：不同类别的均值变化可使总体呈强相关，即使每一类内部近似独立。因此检验假设应关注类内依赖。

将式(**??**)代入式(**??**)，并取对数，得到

$$S_c(\boldsymbol{x})=\log\pi_c+\sum_{i=1}^{m}\log\theta_{c,i,j_i(\boldsymbol{x})},\qquad \hat{c}(\boldsymbol{x})=\arg\max_{c}S_c(\boldsymbol{x}). \tag{2.6}$$

对数的单调性保持排序，并将小概率连乘转换为求和，减轻浮点下溢。令 $M=\max_a S_a(\boldsymbol{x})$，模型给出的后验概率可稳定地计算为

$$\widehat{P}(Y=y_c\mid\boldsymbol{x})=\frac{\exp(S_c(\boldsymbol{x})-M)}{\sum_a\exp(S_a(\boldsymbol{x})-M)}. \tag{2.7}$$

当独立性假设或分布模型不正确时，这只是模型后验的估计，不保证等于真实条件概率。

2.4 参数估计与复杂度

模型的对数似然为

$$\ell(\pi,\theta)=\sum_{c}N_c\log\pi_c+\sum_{c,i,j}N_{c,i,j}\log\theta_{c,i,j}. \tag{2.8}$$

在 $\sum_c\pi_c=1$、$\sum_j\theta_{c,i,j}=1$ 下，极大似然估计为

$$\hat{\pi}_c=\frac{N_c}{N},\qquad \hat{\theta}_{c,i,j}=\frac{N_{c,i,j}}{N_c}\quad (N_c>0). \tag{2.9}$$

例如固定 (c,i)，构造 $\mathcal{L}=\sum_j N_{c,i,j}\log\theta_{c,i,j}+\lambda(1-\sum_j\theta_{c,i,j})$。一阶条件给出 $N_{c,i,j}/\theta_{c,i,j}=\lambda$，归一化后 $\lambda=N_c$，从而得到式(**??**)；零计数对应单纯形边界上的极值。

自由参数量降为

$$p_{\mathrm{NB}}=(k-1)+k\sum_i(k_i-1)=6+7\times16\times2=230. \tag{2.10}$$

计数训练的主要开销为 $O(Nm)$，初始化和保存概率表需 $O(k\sum_i k_i)$；单样本预测为 $O(km)$。强结构约束通常降低估计方差，但可能引入较大的模型偏差。

2.5 拉普拉斯平滑及其取值依据

若 $N_{c,i,j}=0$，极大似然估计便给出零概率，含有该取值的观测在类别 c 下的似然被直接置零。这未必代表结构上的不可能，也可能仅由有限样本造成。本项目 336 个条件概率表单元中，全量训练集有 39 个空格，1000 条训练集有 56 个空格，分别占 11.6% 与 16.7%。

为每一组条件概率指定独立的对称 Dirichlet 先验：

$$(\theta_{c,i,1},\dots,\theta_{c,i,k_i})\sim\mathrm{Dir}(\alpha,\dots,\alpha),\qquad\alpha>0. \tag{2.11}$$

由共轭性，后验参数为 $(N_{c,i,1}+\alpha,\dots,N_{c,i,k_i}+\alpha)$。其后验均值，也即单次新观测的后验预测概率，为

$$\boxed{\hat\theta_{c,i,j}=\frac{N_{c,i,j}+\alpha}{N_c+\alpha k_i}.} \tag{2.12}$$

分母必须增加 αk_i，因为 k_i 个取值分别增加了 α 个伪计数；因此 $\sum_j\hat\theta_{c,i,j}=1$。需要强调，这里使用*后验均值*，并非 Dirichlet 后验众数。同理，若预先确定完整类别集合，类别先验可估计为

$$\hat\pi_c=\frac{N_c+\alpha_0}{N+\alpha_0 k}. \tag{2.13}$$

本项目离散实现默认 $\alpha=\alpha_0=1$。代码由训练数据识别类别，故没有出现的类别不会自动纳入；若需处理缺失类别，应显式传入完整类别集合。

$\alpha=1$ 是经典加一平滑，对应均匀的 $\mathrm{Dir}(1,\dots,1)$ 先验。例如 $N_c=38$、$k_i=3$、$N_{c,i,j}=0$ 时，估计由 0 变为 $1/41\approx0.0244$。其本质是向均匀分布收缩：

$$\hat\theta_{c,i,j}=\frac{N_c}{N_c+\alpha k_i}\frac{N_{c,i,j}}{N_c}+\frac{\alpha k_i}{N_c+\alpha k_i}\frac{1}{k_i}. \tag{2.14}$$

平滑强度应比较*每个类别*、*每个特征*的总伪计数 αk_i 与 N_c，不能将所有概率表的伪计数相加后与 N 比较，因为一条观测同时贡献 m 个特征计数。

正的实数 α 都可用于平滑，取 1 是易解释的默认值，并非理论上唯一或普遍最优的选择。如需调节，应在训练集内验证；当 $N_c\gg\alpha k_i$ 时其影响渐弱。总体等频分箱只约束 $P(X_i)$，不能保证每个 $P(X_i\mid Y=y_c)$ 接近均匀。若 $k_i=k=2$，式(**??**)退化为 $(N_{c,i,j}+1)/(N_c+2)$，与课堂二值情形一致。

2.6 模型性质与解释边界

对离散特征进行独热编码后，式(**??**)是编码空间中的线性得分；这不意味着对原始连续值或类别编码 $0,1,2$ 的线性判别。高斯朴素贝叶斯在各类方差不等时具有不含交叉项的二次判别函数。条件独立性降低了交互结构的表达能力，但只要最大的类别得分排序仍然正确，错误的概率模型也可能获得较好的分类准确率 [**?**]。因此，类别预测质量与概率校准质量应分别评估。

3 干豆分类的离散朴素贝叶斯基准

3.1 分类任务与数据划分

分类属于监督学习：利用带类别标签的样本学习 $f : \mathcal{X} \to \mathcal{Y}$，以预测未见样本的类别。本项目原始输入空间为 $\mathbb{R}^{16}$，离散化后为 $\{0,1,2\}^{16}$，输出为 7 个干豆品种。训练集用于估计参数；验证集或交叉验证用于选择模型与超参数；测试集用于评估确定模型后的预测性能。若用测试结果反复调整模型，最终分数可能偏乐观 [**?**]。

原始文件 `bean_raw.csv` 包含 13611 行、20 列，其中 16 列为形状特征；其余为 `id`、`partition`、`in_train_1000` 与 `Class`。后三类划分或标签信息及样本标识均不作为输入特征。按给定 `partition` 划分训练集与测试集；1000 条训练集为全量训练集的真子集。数据不存在缺失值，训练与测试的样本 ID 无交集，原始文件与离散文件标签按 ID 对齐一致。

表 2 各类别在固定数据划分中的样本数

类别	训练集 1	训练集 2	测试集
BARBUNYA	925	97	397
BOMBAY	365	38	157
CALI	1141	120	489
DERMASON	2482	260	1064
HOROZ	1350	142	578
SEKER	1418	149	609
SIRA	1845	194	791
合计	9526	1000	4085

3.2 离散化方式的核对

任务提供的离散文件将每个特征编码为 $0,1,2$，但未附分箱程序。本文将原始值与编码按 ID 逐条核对：使用 9526 条训练样本排序后第 3176 与第 6351 个值作为切点，采用右闭区间，即 $(-\infty, q_1]$、$(q_1, q_2]$、$(q_2, +\infty)$，能完全重现 16 个特征、全部 13611 个样本的离散编码。这与训练集三分位分箱一致；例如 Area 的切点为 38923 与 53381，不同于全体数据的三分位数 38989.33 与 53226.67。

据此，现有数据不支持“使用全体样本分位数分箱并造成测试泄漏”的判断。由于缺少原始预处理脚本，本文报告可完全重现编码的规则，而不推断其历史实现过程。在训练集内，各特征三个水平的频数均为 3176、3175、3175。三分位分箱的主要代价是同一箱内的数值差异被丢弃。此外，第 2 步的交叉验证直接使用已经分好的箱，分箱边界没有在每个训练折重新估计，因此其 CV 是对固定离散表示的诊断，而非完整预处理流程的无泄漏评估。

3.3 实验设置与评价指标

分别使用 1000 条与 9526 条训练样本训练 `CategoricalNB`，默认条件概率及先验均加一平滑，在同一 4085 条测试集上评估。准确率为正确预测比例；对类别 c，

$$\mathrm{Precision}_c = \frac{TP_c}{TP_c + FP_c}, \quad \mathrm{Recall}_c = \frac{TP_c}{TP_c + FN_c}, \quad F1_c = \frac{2\,\mathrm{Precision}_c\,\mathrm{Recall}_c}{\mathrm{Precision}_c + \mathrm{Recall}_c}. \tag{3.1}$$

宏平均 F1 对各类等权，加权平均 F1 按测试样本数加权。混淆矩阵以真实类别为行、预测类别为列。多数类基线总是预测训练集中最多的 DERMASON 类。

第 2 步的五折验证按随机种子 7 打乱后等分，*没有分层*；表中的“±”为五个折分数的标准差，不是均值标准误或置信区间。学习曲线及 300 次子集实验固定测试集，仅改变训练子集，用于描述给定数据划分下的稳定性，不作为新的独立测试证据。

3.4 两个训练规模的主要结果

表 3 固定测试集上的分类结果与训练集内部诊断

指标	多数类基线	训练集 2	训练集 1
训练样本数	9526	1000	9526
测试准确率（%）	26.05	83.40	83.87
正确数 / 4085	1064	3407	3426
宏平均 F1	—	0.7890	0.7994
加权平均 F1	—	0.8343	0.8386
五折 CV 准确率（%）	—	81.60 ± 2.92	84.13 ± 0.31
重代入准确率（%）	—	82.30	84.14

两个模型均明显优于多数类基线。全量模型训练与测试准确率接近，与参数量较小、结构限制较强的模型特征一致。但训练与测试分数接近本身不能证明不存在过拟合；尤其训练集 2 的重代入分数低于测试分数，不能将其解释为已经“记住”训练样本。训练集 2 的验证折仅约 200 条，当准确率约 0.82 时，二项近似下单折分数的标准误约为 2.7 个百分点，其折间波动不能全部归因于训练算法不稳定。

表 4 全量离散朴素贝叶斯的分类别测试指标

类别	Precision	Recall	F1	样本数
BARBUNYA	0.871	0.698	0.775	397
BOMBAY	0.567	0.567	0.567	157
CALI	0.687	0.836	0.755	489
DERMASON	0.933	0.866	0.898	1064
HOROZ	0.882	0.901	0.891	578
SEKER	0.826	0.977	0.895	609
SIRA	0.856	0.776	0.814	791

全量模型对 BOMBAY 的召回率仅为 0.567：157 个样本中，57 个被判为 CALI、11 个被判为 BARBUNYA。DERMASON 与 SIRA、CALI 与 BARBUNYA 也存在混淆。SEKER 的召回率为 0.977，精确率为 0.826，意味着不少其他类别样本被判入该类；仅凭这一现象不能确定其成因是先验、分布宽度还是相关特征的重复计数。

3.5 平滑与训练样本量的影响

全量训练集的 CV 分数在 $\alpha \in [0, 10]$ 内变化不足 0.1 个百分点；1000 条训练集的变化范围约为 0.6 个百分点，不能对两个规模统一宣称“变化不足 0.1”。本实验采用可解释的默认值 $\alpha = 1$，

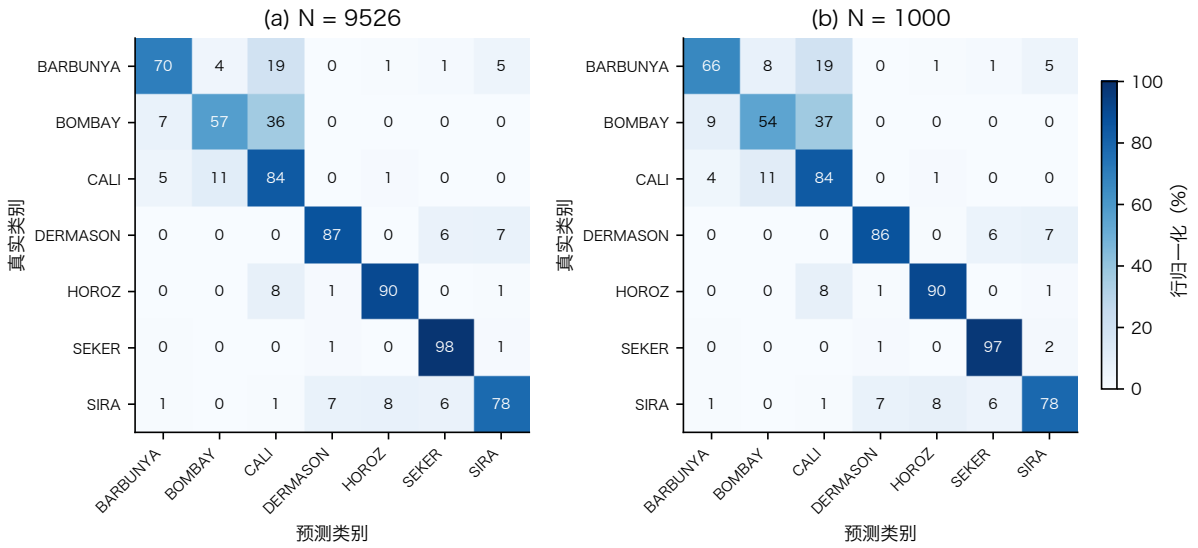


图 1 两个训练规模的混淆矩阵。格内为行归一化百分比，颜色使用相同尺度。

表 5 平滑系数的五折 CV 准确率（%）；$\alpha = 0$ 使用代码中的有限负数近似处理零概率

α	0	0.1	0.2	0.5	1	2	5	10
训练集 1	84.12	84.12	84.12	84.13	84.13	84.12	84.08	84.04
训练集 2	81.80	81.50	81.50	81.70	81.60	81.70	81.70	81.20

没有根据测试结果重新选取平滑系数。

补充实验在 $N = 20$ 时，$\alpha = 0$ 与 $\alpha = 1$ 的平均测试准确率分别为 64.89% 与 69.27%，$N = 1000$ 时分别为 83.44% 与 83.55%。不过，两种 α 使用的是分别抽取的随机子集，且很小的子集可能缺失类别或特征水平，因此这些均值只提供平滑在稀疏样本中可能有帮助的探索性证据，不能视为严格配对的处理效应。更严谨的比较应固定同一批子集，并预先指定所有类别和每个特征的取值集合。

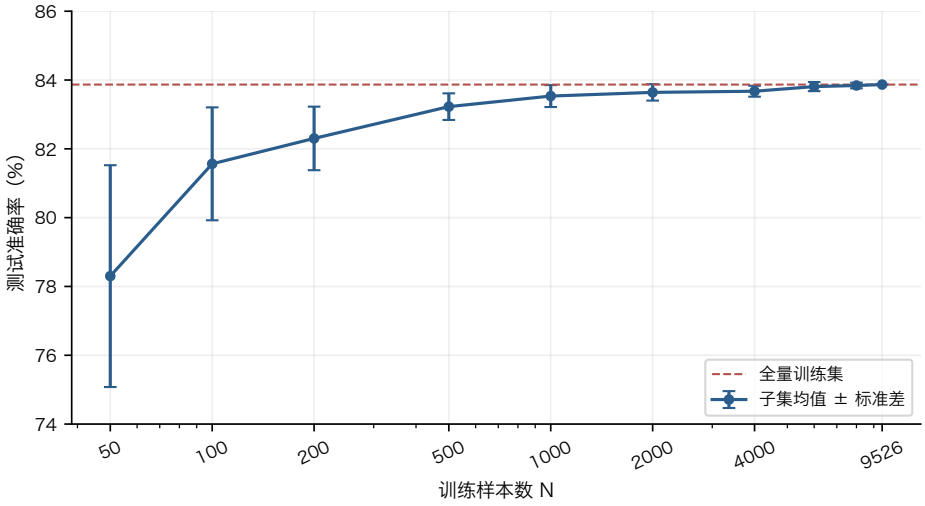


图 2 离散模型的学习曲线。每个规模随机抽取子集 10 或 30 次；误差棒为固定测试集上分数的子集间标准差。

从 $N = 50$ 到 $N = 1000$，平均准确率由 78.30% 升至 83.53%；继续增加到 9526 条时为 83.87%。

这支持在当前特征表示与模型下，约 1000 条后新增样本的边际收益较小，误差可能更多受模型结构限制。学习曲线并非严格的偏差分解，也不能将 $N \approx 1000$ 作为适用于其他数据集的普遍阈值。

3.6 准确率差异：统计显著性与实际幅度

全量模型比 1000 条模型多判对 19 个样本，即 $19/4085 = 0.4651$ 个百分点。由于两个模型使用同一批测试样本，比较必须保留配对结构。

表 6 两个离散模型在测试集上的配对正确性计数

	1000 条模型正确	1000 条模型错误	合计
全量模型正确	3390	36	3426
全量模型错误	17	642	659
合计	3407	678	4085

McNemar 检验仅使用不一致的正确性计数 $b = 36, c = 17$。连续性校正统计量为 $\chi^2 = (|36 - 17| - 1)^2/(36 + 17) = 6.113$，近似 $p = 0.0134$；精确双侧二项检验为

$$p_{\text{exact}} = 2P\{B \le 17\}, \qquad B \sim \text{Bin}(53, 1/2), \quad p_{\text{exact}} = 0.0127. \tag{3.2}$$

定义 $D_t = \mathbf{1}\{\hat{y}_{\text{full},t} = y_t\} - \mathbf{1}\{\hat{y}_{1000,t} = y_t\}$。在测试样本独立的近似下，使用配对差的样本标准差 s_D，准确率差的近似 95% Wald 区间为

$$\bar{D} \pm 1.96\frac{s_D}{\sqrt{4085}} = [0.00116,\ 0.00814], \tag{3.3}$$

即 $[0.12, 0.81]$ 个百分点。该区间与 McNemar 结论一致，避免了将两份高度相关的预测误按独立比例计算区间。它仅反映给定两个训练结果的测试样本不确定性，不包含重新抽取训练集的变化，也受固定基准数据及给定预处理条件的限制。

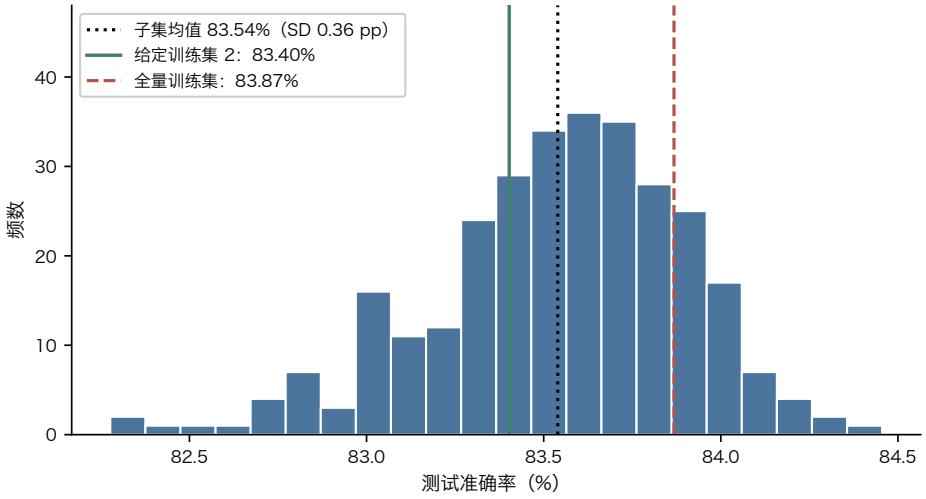


图 3 300 个随机 1000 条训练子集的测试准确率分布；给定训练集 2 约位于第 29 百分位。

300 次随机子集实验的平均准确率为 83.54%，标准差为 **0.36 个百分点**，经验 2.5%–97.5% 分位区间为 $[82.77\%, 84.14\%]$。给定训练集 2 的 83.40% 比子集均值低约 0.14 个百分点，属于常见

波动。全量模型比随机子集均值高约 0.33 个百分点，提示样本量仍有小幅收益；不能据此将全部差异归为随机误差，也不能把经验分位区间当作两个模型差值的置信区间。

因此，对任务中的“是否有明显差异”，较准确的回答是：**全量模型在该测试集上有可检出的统计优势，但准确率提升不到半个百分点，实际幅度较小**。若“明显”指统计显著，应回答有差异；若指较大的应用收益，则应强调收益有限。

4 连续特征与条件独立性的讨论

4.1 以条件密度处理连续特征

条件独立性不要求特征有限取值。对连续特征，将概率质量替换为一维类条件密度 $f_{c,i}(x_i)$，模型后验与得分为

$$\widehat{P}(Y=y_c \mid \boldsymbol{x}) = \frac{\hat{\pi}_c \prod_i \hat{f}_{c,i}(x_i)}{\sum_a \hat{\pi}_a \prod_i \hat{f}_{a,i}(x_i)}, \qquad S_c(\boldsymbol{x}) = \log \hat{\pi}_c + \sum_i \log \hat{f}_{c,i}(x_i). \tag{4.1}$$

密度值可以大于 1，并非单点事件的概率；分类仍比较各类别的相对得分。

4.1.1 高斯朴素贝叶斯

假设 $X_i \mid Y=y_c \sim \mathcal{N}(\mu_{c,i}, \sigma_{c,i}^2)$，均值与方差的极大似然估计为

$$\hat{\mu}_{c,i} = \frac{1}{N_c} \sum_{n:y^{(n)}=y_c} x_i^{(n)}, \qquad \hat{\sigma}_{c,i}^2 = \frac{1}{N_c} \sum_{n:y^{(n)}=y_c} (x_i^{(n)} - \hat{\mu}_{c,i})^2. \tag{4.2}$$

对每个方差加入很小的正则项 ε 后，令 $v_{c,i} = \hat{\sigma}_{c,i}^2 + \varepsilon$，则

$$S_c(\boldsymbol{x}) = \log \hat{\pi}_c - \frac{1}{2} \sum_i \left[\log(2\pi v_{c,i}) + \frac{(x_i - \hat{\mu}_{c,i})^2}{v_{c,i}} \right]. \tag{4.3}$$

均值与方差共 $2km = 224$ 个参数，加上类别先验共 230 个，与离散模型同量级。项目实现先用训练集统计量标准化，再以 `var_smoothing=1e-9` 稳定方差。

理想的、没有附加正则项的高斯模型对逐维可逆仿射变换具有分类不变性，因为变换的 Jacobian 对所有类别相同。实际的方差平滑可能破坏这种不变性：例如以所有特征中的最大方差确定统一 ε 时，大尺度特征可能使小尺度特征被过度平滑 [**?**]。因此先标准化既使正则化尺度合理，也便于数值计算；不能把原始尺度下的性能差异简单归因于对数密度公式必然发生“大数相消”。

4.1.2 核密度朴素贝叶斯

以一维高斯核 φ 估计每个类条件密度：

$$\hat{f}_{c,i}(x) = \frac{1}{N_c h_{c,i}} \sum_{n:y^{(n)}=y_c} \varphi\left(\frac{x - x_i^{(n)}}{h_{c,i}} \right), \quad h_{c,i} = 1.06\, s_{c,i} N_c^{-1/5}, \tag{4.4}$$

其中 $s_{c,i} = \min(\mathrm{sd}_{c,i}, \mathrm{IQR}_{c,i}/1.349)$，IQR 为四分位距。本文直接给出实际使用的经验带宽，避免将不同系数的 Scott 与 Silverman 规则混称。实现对每个类别、每个特征在 1024 个网格点上计算对数密度，再线性插值；网格范围为该类最小值减 $3h$ 至最大值加 $3h$，区间外采用端点对数密度。这是一种计算近似，尾部外推与带宽选择均可能影响结果。拟合后实际保存的是网格及其对数密度，共约 $2 \times 7 \times 16 \times 1024 = 229376$ 个数，而非保存所有训练点用于逐点预测。

表 7 离散及连续朴素贝叶斯的固定测试集表现

方法	准确率（%）	宏平均 F1	正确样本数
三水平离散 NB	83.87	0.7994	3426
高斯 NB	89.84	0.9083	3670
核密度 NB	90.04	0.9080	3678
高斯 NB + $\log(1+x)$	89.72	—	3665

表 8 连续模型的分类别召回率及相对离散模型的正确样本净增量

类别	离散 NB	高斯 NB	KDE NB	高斯净增数
BARBUNYA	0.698	0.806	0.796	+43
BOMBAY	0.567	1.000	0.994	+68
CALI	0.836	0.906	0.892	+34
DERMASON	0.866	0.866	0.889	+0
HOROZ	0.901	0.962	0.955	+35
SEKER	0.977	0.952	0.954	-15
SIRA	0.776	0.876	0.874	+79

4.1.3 结果与信息损失分析

高斯模型比离散模型多判对 244 个样本，提升 5.97 个百分点。其中 BOMBAY 从 89 个正确增加到 157 个正确，净增 68 个，占总净增的 27.9%；SIRA 净增 79 个，BARBUNYA、CALI、HOROZ 也有改善，而 SEKER 略有下降。因此，BOMBAY 是信息损失的直观例子，不能说全部或几乎全部增益都由它贡献。

BOMBAY 的面积、周长、长短轴、凸包面积与等效直径较大，粗分箱将很多样本压入最高水平，削弱其与 CALI、BARBUNYA 等较大品种的区分；连续模型保留了箱内幅度。这一解释与分类别结果一致，但离散 NB 与高斯 NB 同时改变了表示和似然模型，不能把 5.97 个百分点严格视为单独改变表示的因果效应。KDE 仅比高斯模型高 8 个正确样本，尚不足以据此断言类内分布接近正态或二者存在显著性能差异。

4.2 独立性假设是否合理

4.2.1 总体相关性、类内相关性与确定性关系

训练集 120 对特征中有 21 对满足 $|r| > 0.9$，其中 3 对满足 $|r| > 0.99$。更直接的证据是以下定义关系在数据中达到机器精度：

$$\text{EquivDiameter} = \sqrt{4\text{Area}/\pi}, \qquad \text{Solidity} = \text{Area}/\text{ConvexArea}. \tag{4.5}$$

确定性依赖不同于 Pearson 线性相关系数等于 1。Area 与 EquivDiameter 是非线性函数关系，在训练集上的 Pearson 系数约为 0.9850，不能称为“完全线性相关”。若类内 Area 非退化，其非恒定确定性变换便不可能与 Area 条件独立。

按各类别分别计算相关系数，再对 7 个类别等权平均，Area–EquivDiameter 为 0.9990，Area–ConvexArea 为 0.9994，AspectRation–Eccentricity 为 0.9779。因此依赖关系并非仅由类别混合造成，朴素贝叶斯的条件独立性在本数据中明显不成立。

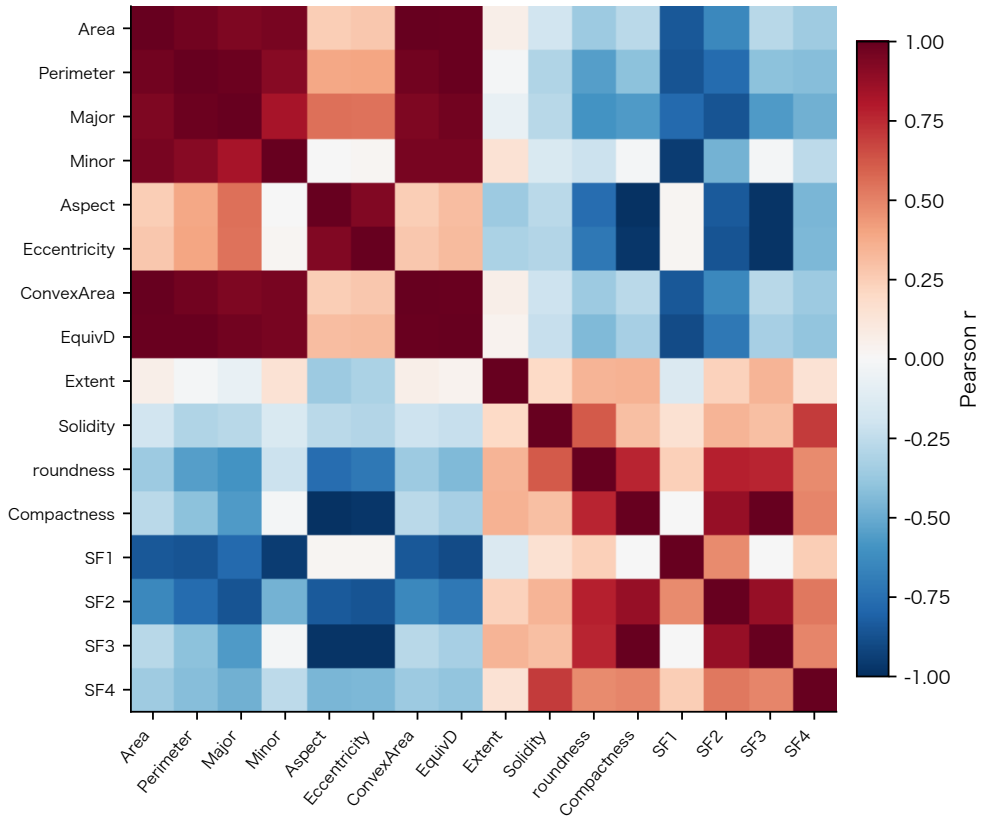


图 4 原始连续训练特征的 Pearson 相关矩阵；该矩阵使用训练集而非全体样本。

4.2.2 重复特征如何改变分类

复制一个已有特征不会增加真实信息，但复制后的变量与原变量高度依赖，朴素贝叶斯的乘积分解会将其再次计入。若特征 i 总共出现 w 次，得分变为

$$S_c^{(w)}(\boldsymbol{x}) = \log \hat{\pi}_c + w \log \hat{\theta}_{c,i,j_i(\boldsymbol{x})} + \sum_{\ell \neq i} \log \hat{\theta}_{c,\ell,j_\ell(\boldsymbol{x})}. \tag{4.6}$$

故复制等价于提高该特征的权重，并不保证类别排序不变。例如某两个类别的对数得分差中，该特征贡献 -0.4、其余项贡献 0.6，原差为 0.2；复制一次后差变为 $-0.8 + 0.6 = -0.2$，预测类别即反转。即使复制的是完全相同的特征，也可能发生这种情况。

表 9 重复特征实验的测试准确率（%）；w 表示每个指定特征出现的总次数

w	1	2	3	4	6	8	12
只重复 Area	83.87	83.84	83.77	83.92	83.87	83.08	74.59
同时重复两项	83.87	83.77	83.94	83.84	78.26	—	—

Area 出现 2–6 次时准确率约为 83.77%–83.92%，变化较小；出现 12 次时降至 74.59%。同时将 Area 与 EquivDiameter 各计入 6 次时为 78.26%。高斯 NB 增加一列 2Area 后准确率仍为 89.84%，但这是本次实验的结果，并非一般性不变定理。同样，平均最大后验随重复次数可能上升也可能下降；离散 Area 过度重复时该值从 0.976 降至 0.949，不能将“复制必然使后验更尖锐”作为普遍结论。

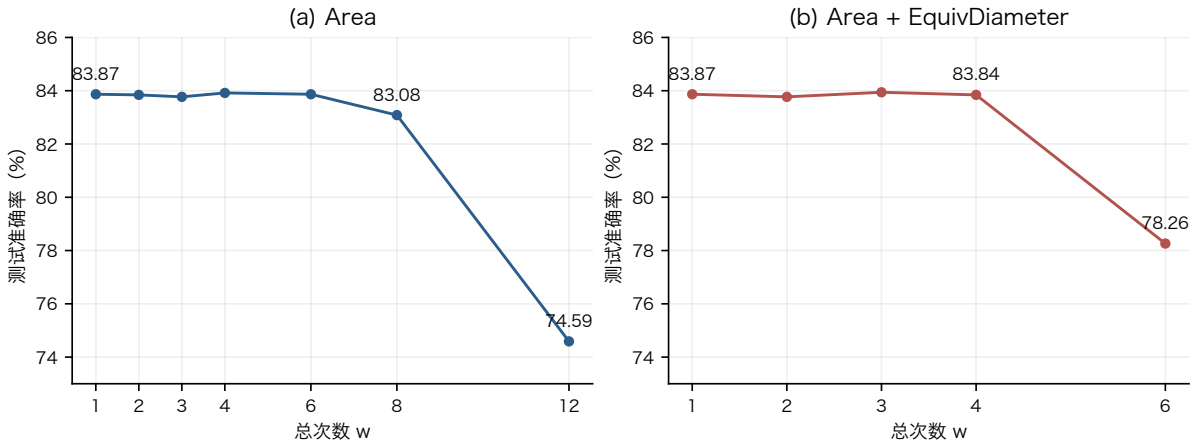


图 5 重复特征对离散 NB 的影响。左右子图均按各特征出现的总次数计。

表 10 若干逐特征删除实验（离散 NB，固定测试集）

删除特征	准确率（%）	相对基准（百分点）
无（基准）	83.87	0.00
Area	83.45	-0.42
EquivDiameter	83.45	-0.42
ConvexArea	83.23	-0.64
Eccentricity	84.50	+0.64
AspectRation	84.50	+0.64
Compactness	84.38	+0.51

4.2.3 删除特征与概率校准

删除 Eccentricity 或 AspectRation 后准确率由 83.87% 升至 84.50%，提示冗余特征的权重分配可能损害部分决策；删除 Area 或 EquivDiameter 后为 83.45%。单个删除影响较小只说明该特征在其余特征仍保留时的边际作用有限，不能推断整组相关特征“仅留一个即可”。这些测试集消融结果用于解释，不作为重新选择最终模型的依据。

全量离散 NB 的平均最大后验为 97.60%，实际准确率为 83.87%；后验超过 0.99 的样本占 81.18%，其准确率仍只有 89.87%。这提供了明显的过度自信证据，但没有完整刻画所有概率区间的校准情况。若后续任务依赖可信概率，应另用训练集内部的校准折评估可靠性曲线、对数损失或 Brier 分数，并比较 sigmoid 或 isotonic 校准；本文未实施这一步。

分类只要求最大后验类别正确，概率估计则要求数值接近真实条件概率，后者要求更强。这解释了相关性很强时模型仍能保持一定分类能力的可能性 [**?**, **?**]，但不能由本次重复实验推断条件依赖一般只影响概率而不影响类别。

5 连续特征上的分类改进

5.1 模型选择与评估流程

任务第 4 步允许使用原始连续特征及其他模型，但要求在相同的 `partition=TEST` 样本上报告准确率，并尽力避免过拟合测试集。原程序在 9526 条训练样本上使用五折分层交叉验证，

`StratifiedKFold(n_splits=5, shuffle=True, random_state=42)`，对 21 个候选计算平均准确率；最终模型由 CV 均值最大者确定。标准化放在 `Pipeline` 中，每折只拟合该折训练部分的均值与标准差。逐样本的固定比值和对数运算不依赖其他样本统计量，可在划分验证折之前计算。

原程序在全部候选的 CV 完成后，分别报告每个候选的测试结果，最终选择表达式只依赖 CV 分数。因此应称为“按训练集 CV 选择，并对候选统一进行测试”，而非整个项目“只查看过一次测试集”。第 2、3 步还使用同一测试集做了多种诊断；这些探索不能由 CV 与测试分数接近而被证明毫无选择偏差。本文不利用新复核结果再次调参，也不将测试分数最高的候选替换为最终模型。

5.2 预处理与特征工程

所有 16 个原始连续特征均保留。对任一特征，用当前训练折的均值与总体标准差计算 $z_i = (x_i - \mu_i)/s_i$，测试折使用相同变换；不做按全体数据拟合的标准化。代码对各模型统一添加 `StandardScaler`，包括树模型；树方法通常不依赖特征量纲，但复现时仍按原管线保留该步骤。

在 16 维基础上增加 11 个确定性变换。设 A, P, L, l, H, D 分别为面积、周长、长轴、短轴、凸包面积和等效直径，则新增特征见表**??**。部分特征与原变量同义或互为函数；它们不增加观测信息，但可改变不同模型的表示与归纳偏好。“27 个特征”因而不等于 27 个独立信息来源。

表 11 新增特征的精确定义（名称与代码一致）

特征名	定义	特征名	定义
`solidity2`	A/H	`roundness2`	$4\pi A/P^2$
`compactness2`	$P^2/(4\pi A)$	`aspect2`	L/l
`major_per_P`	L/P	`minor_per_P`	l/P
`eqd_per_P`	D/P	`area_per_majmin`	$A/(Ll)$
`sf3_alt`	$(H-A)/H$	`log_area`	$\log A$
`log_perimeter`	$\log P$		

另设 11 维精简特征集：从原 16 维中删除 Area、ConvexArea、EquivDiameter、AspectRation 与 Compactness。原字段 `AspectRation` 沿用数据文件拼写。

5.3 候选模型与最终算法

候选包含高斯 NB、线性与二次判别分析（LDA、QDA）、逻辑回归、距离加权 k 近邻、RBF 核支持向量分类器（SVC）、随机森林、极端随机树、直方图梯度提升及软投票。主要参数见表**??**，完整候选对应 `code/run_step4.py`。

软投票代码重新克隆成员模型后统一使用 27 维并集，因此其成员并非全部等同于表中各自的 16 维独立候选。不能直接用独立候选的分数或未经保存的预测一致率，定量解释投票分数的变化。

最终 SVC 的 RBF 核为

$$K(\boldsymbol{z}, \boldsymbol{z}') = \exp[-\gamma \|\boldsymbol{z} - \boldsymbol{z}'\|^2]. \tag{5.1}$$

C 控制分类间隔与训练误差的权衡，`gamma=scale` 使用 $\gamma = 1/(d\,\mathrm{Var}(Z))$，其中 d 为特征数。多分类使用 scikit-learn SVC 的一对一训练方式。27 维特征使核距离发生变化，故即使新增特征

表 12 主要候选配置；标准化均由折内管线执行

模型	参数设置	特征维数
高斯 NB / LDA	默认参数	16
QDA	`reg_param=0.05`	16
逻辑回归	$C = 1$，`max_iter=3000`	16
k 近邻	$k \in \{5, 9, 15, 25\}$，距离加权	16
SVC	RBF；$C \in \{1, 10, 100\}$；$\gamma =$ `scale`	16
SVC 特征变体	RBF；$C = 10$；$\gamma =$ `scale`	11 / 27
随机森林 / 极端随机树	500 棵树，`random_state=42`	16 / 27
直方图梯度提升	400 次迭代，学习率 0.08，31 个叶节点，$L_2 = 1$	16 / 27
梯度提升变体	500 次迭代，学习率 0.06，63 个叶节点，$L_2 = 0.5$	27
软投票	SVC、RF、ET、HistGB 与 LR 等权概率平均	27

是确定性变换，也可能改变判别结果。参数空间未进行无上限搜索；最终配置为标准化、27 维、$C = 10$。

5.4 改进结果与分类别表现

表 13 全部候选的五折 CV 与测试准确率（%，按未四舍五入的 CV 均值降序）

模型	维数	CV	测试	CV − 测试
SVC（27 维，$C = 10$）	27	93.04	93.29	-0.25
SVC（11 维，$C = 10$）	11	93.01	93.24	-0.23
SVC（16 维，$C = 100$）	16	92.98	93.27	-0.29
SVC（16 维，$C = 10$）	16	92.98	93.37	-0.39
软投票（27 维）	27	92.98	92.97	+0.00
SVC（16 维，$C = 1$）	16	92.85	92.95	-0.10
HistGB（27 维，63 叶）	27	92.66	92.46	+0.20
HistGB（16 维）	16	92.55	92.22	+0.33
极端随机树（27 维）	27	92.53	92.22	+0.31
HistGB（27 维，31 叶）	27	92.50	92.24	+0.26
随机森林（27 维）	27	92.43	92.51	-0.08
kNN（$k = 15$）	16	92.43	92.31	+0.12
kNN（$k = 9$）	16	92.34	92.24	+0.10
kNN（$k = 5$）	16	92.29	92.04	+0.25
随机森林（16 维）	16	92.29	92.17	+0.13
逻辑回归	16	92.27	92.78	-0.50
kNN（$k = 25$）	16	92.22	92.71	-0.48
QDA	16	91.95	92.31	-0.36
极端随机树（16 维）	16	91.92	92.17	-0.25
LDA	16	90.45	90.09	+0.36
高斯 NB	16	89.66	89.84	-0.18

CV 最高的 27 维 SVC 平均准确率为 93.04%，固定测试集上为 **93.29%（3811/4085）**，较离散基准提高 9.42 个百分点，错误样本从 659 个减少至 274 个。复核使用 scikit-learn 1.6.1，保留原始 CSV 行序及相同分折种子，重现了该 CV 均值与测试正确数。

表 14 按 CV 选择的最终 SVC 的分类别测试指标

类别	Precision	Recall	F1	样本数
BARBUNYA	0.952	0.904	0.928	397
BOMBAY	1.000	1.000	1.000	157
CALI	0.926	0.953	0.940	489
DERMASON	0.925	0.933	0.929	1064
HOROZ	0.968	0.946	0.957	578
SEKER	0.951	0.962	0.957	609
SIRA	0.885	0.889	0.887	791
宏平均	0.944	0.941	0.942	4085
加权平均	0.933	0.933	0.933	4085

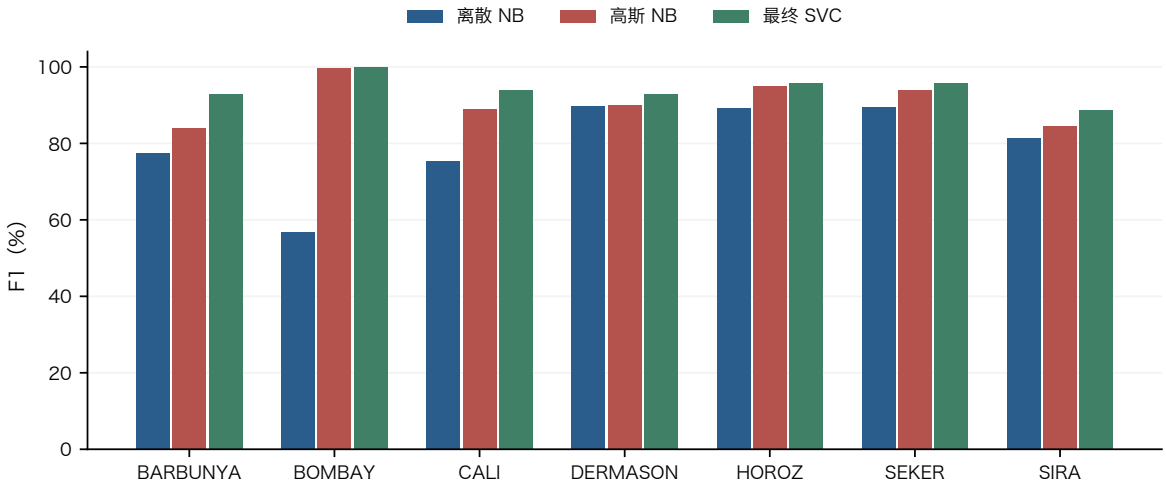


图 6 各类别 F1 比较。最终模型为按 CV 选定的 27 维 SVC。

BOMBAY 的精确率与召回率均为 1；其他各类 F1 也得到提高。主要残余错误为 SIRA 与 DERMASON 之间的互相错分，共 118 个，占全部错误的 43.1%。这说明当前模型对这两个类别仍有区分困难，但不足以证明 16 个原始特征已达到理论可分辨上限。

5.5 改进来源及解释的限制

第一，连续模型保留箱内幅度，其分数比离散模型高约 6 个百分点，支持粗分箱存在信息损失的解释。但似然分布也同时改变，故该差值不是纯粹表示效应。第二，最终 SVC 比高斯 NB 高约 3.45 个百分点，与其可以学习更灵活的非线性边界、无需类条件独立假设相一致。然而模型族、优化目标、正则化与特征表示均有变化，不能把差值完全归因为“放松独立性”。

第三，显式特征工程的收益较小且不稳定：27 维与 16 维 SVC 的 CV 均值仅差约 0.06 个百分点；测试上 16 维反而高约 0.07 个百分点（四舍五入后的分数相减为 0.08）。本实验未对这两个

表 15 模型与表示的阶段性比较；增量均以全量离散 NB 为基准

模型	特征表示	准确率（%）	增量（百分点）
离散 NB（1000 条）	16 维三水平	83.40	−0.47
离散 NB（全量）	16 维三水平	83.87	0.00
高斯 NB	16 维连续	89.84	+5.97
核密度 NB	16 维连续	90.04	+6.17
SVC（16 维，$C = 10$）	16 维连续	93.37	+9.50
最终 SVC（27 维）	连续值及确定性变换	93.29	+9.42

模型进行配对差异检验，因此不声称其中一个具有稳定优势。按 CV 规则仍采用 27 维版本，不因其测试分数略低而更换。

第四，软投票低于最终单模型，只能说明当前成员配置与等权组合未带来收益；树模型在本实验中略低于 SVC，也不能由此推出所有树方法或所有超参数下均不如核方法。附录的随机森林重要性仅解释该随机森林的拟合，不代表最终 SVC 的特征贡献。

最后，21 个候选的 CV 与测试分数差距较小，说明两种评估在该划分上大体一致，但不能用差值正负是否均衡来证明未发生测试集过拟合。进一步验证需使用独立新测试集，或在训练数据内部进行外层验证与内层调参分离的嵌套交叉验证。

6 结论与局限

本文完成了有限多值特征与多类别朴素贝叶斯的推导，并按任务书要求比较了两个训练规模、讨论了连续特征与相关特征，最后通过连续表示与支持向量机改善分类结果。

模型层面，条件独立性使本项目的自由参数量从约 3.0×10^8 降至 230；拉普拉斯平滑通过 $(N_{c,i,j} + \alpha)/(N_c + \alpha k_i)$ 避免有限样本的零频数直接产生零概率。$\alpha = 1$ 是有清晰先验解释的默认值，其有效强度由 $\alpha k_i / N_c$ 决定。

实验层面，1000 条与 9526 条离散模型准确率分别为 83.40% 与 83.87%。配对检验说明全量模型有统计优势，但仅多判对 19 个样本；学习曲线与随机子集分布共同提示当前模型下继续增加训练数据的收益递减。连续高斯与 KDE 模型达到 89.84% 与 90.04%，说明避免粗离散化有较大潜在价值。

解释层面，类内强相关与确定性关系表明独立性假设不成立。部分轻度重复或单特征删除只产生小幅变化，但过度重复可使准确率明显下降；平均最大后验与实际准确率的差距也表明概率输出应单独校准和验证。分类稳健性不能等同于独立性成立，更不能等同于概率可信。

改进层面，按五折分层 CV 选择的 27 维标准化 RBF SVC 在固定测试集上达到 93.29%，较全量离散基准提高 9.42 个百分点。该结果支持保留连续信息与使用更灵活判别函数的实际价值，但阶段性分数差不是各机制贡献的严格因果分解。

本研究仍受以下限制：离散模型的 CV 未在折内重新拟合分箱；重复使用同一测试集进行诊断使其难以作为完全盲测；小样本平滑实验未采用严格配对子集，且代码由观测数据推断类别与取值集合；候选模型的比较未使用嵌套 CV，概率评估也未覆盖可靠性曲线等指标。现有数据可以支持本文对固定划分的结果陈述，但尚不能证明最优分类上限、模型间微小差异的稳定性，或任何改进机制的唯一解释。后续工作应优先改善验证设计与概率评估，而不是继续根据测试分数扩展搜索。

参考文献

[1] 深圳理工大学基础教学部. 概率论与数理统计探究项目：朴素贝叶斯模型 [Z]. 课程任务书（项目所附PDF）.

[2] KOKLU M, OZKAN I A. Dry Bean [DS]. UCI Machine Learning Repository, 2020. doi:10.24432/C50S4B.

[3] KOKLU M, OZKAN I A. Multiclass classification of dry beans using computer vision and machine learning techniques[J]. Computers and Electronics in Agriculture, 2020, 174: 105507. doi:10.1016/j.compag.2020.105507.

[4] DOMINGOS P, PAZZANI M. On the optimality of the simple Bayesian classifier under zero-one loss[J]. Machine Learning, 1997, 29: 103–130. 论文全文.

[5] SCIKIT-LEARN DEVELOPERS. Naive Bayes; GaussianNB[EB/OL]. [2026-11-05]. `https://scikit-learn.org/stable/modules/naive_bayes.html`; `https://scikit-learn.org/stable/modules/generated/sklearn.naive_bayes.GaussianNB.html`.

[6] SCIKIT-LEARN DEVELOPERS. Cross-validation: evaluating estimator performance[EB/OL]. [2026-11-05]. `https://scikit-learn.org/stable/modules/cross_validation.html`.

A 任务要求对应与复现说明

A.1 任务要求对应

表 16 课程任务书与本文内容的对应关系

任务	内容	对应位置
第 1 步（1）	贝叶斯公式与维数灾难	第**??**节
第 1 步（2）–（3）	相互条件独立、后验与判别、参数估计	第**??**节
第 1 步（4）	平滑修正值及其理由	第**??**节
第 2 步（1）–（3）	分类定义、训练测试作用、两种规模准确率	第**??**节
第 2 步（4）	准确率差异与解释	第**??**节
第 3 步（1）	连续特征的高斯与 KDE 模型	第**??**节
第 3 步（2）	独立性与相关特征的重复使用	第**??**节
第 4 步（1）–（2）	可复现的预处理、参数、准确率与改进解释	第**??**节

A.2 项目文件与运行方法

本项目的开源仓库地址为：`https://github.com/ty-yqs/naive_bayes`。原始数据见 `bean_raw.csv`；离散数据见 `bean_train.csv`、`bean_train_1000.csv` 与 `bean_test.csv`。原始数值结果见 `results/step2.json`、`step3.json`、`extra.json` 与 `step4.json`；复核新增 `results/latex_audit.json`，不覆盖原始结果。模型代码位于 `code/`，本论文源码及矢量图表位于 `latex/`。

在 `naive_bayes/` 目录执行：

```
python -m pip install -r requirements.txt
python code/run_step2.py
python code/run_step3.py
python code/run_extra.py
python code/run_step4.py
python code/make_figures.py
python latex/audit_report.py --verify-svc
```

上述原始脚本会重新生成相应结果文件；仅核对论文时可直接运行最后一条。完整实验需要 NumPy、pandas、scikit-learn 与 matplotlib，原项目环境为 Python 3.9、NumPy 2.0.2、pandas 2.2.3、scikit-learn 1.6.1、matplotlib 3.9.4。`requirements.txt` 为版本下限约束，并非锁定环境；跨版本的微小差异不应被解释为数据改变。

第 2 步子集抽样使用 NumPy 生成器种子 20261102，五折打乱种子 7；补充平滑实验种子为 7；第 4 步分层分折及树模型种子为 42。还需保留原始 CSV 的行序，因为固定随机种子并不能消除行序对交叉验证划分的影响。SVC 的 `probability=True` 内部概率估计未单独设置随机种子，不宜宣称全部概率输出逐位可复现；本文复核以 CV 准确率和预测类别为依据。

编译论文时，在 `latex/` 目录执行：

```
latexmk -xelatex -interaction=nonstopmode -halt-on-error main.tex
```

或在 Overleaf 中选择 XeLaTeX 编译 `main.tex`。源码采用 TeX Live 自带 Fandol 中文字体及 TeX Gyre 西文字体，已生成的图表可直接使用，不要求安装原作者的 macOS 字体。重新生成矢量图表可运行 `prepare_assets.py`。

A.3 训练集分箱边界

表 17 能完全重现给定离散文件的训练集三分位切点（此表为显示取舍，精确值见复核 JSON）

特征	第一切点	第二切点
Area	38923	53381
Perimeter	730.217	910.43
MajorAxisLength	265.121779	354.30249
MinorAxisLength	182.22673	203.534217
AspectRation	1.47650788	1.63954784
Eccentricity	0.735731128	0.792459715
ConvexArea	39327	54205
EquivDiameter	222.616942	260.704431
Extent	0.733688699	0.77854982
Solidity	0.986781166	0.989414009
roundness	0.852619707	0.906029756
Compactness	0.778493352	0.821388178
ShapeFactor1	0.00627609261	0.00701691233
ShapeFactor2	0.00133090601	0.00200853126
ShapeFactor3	0.606051898	0.674678539
ShapeFactor4	0.994848775	0.997413187

右闭区间的规则对边界上的样本很重要。直接计算浮点分位数时，某些切点可能因表示误差与排序值相差约 10^{-14}；复核采用确切的训练集顺序统计量，以避免将边界误差误认为不同预处理。

A.4 实现细节

离散代码对 $\alpha = 0$ 的 $-\infty$ 用 -10^{10} 代替；对训练中未见的特征取值，则跳过该项。跳过未见水平并不等价于赋零概率，这一策略不会影响本次全量基准中所有水平已出现的情形，但会影响极小训练子集的解释。因此理论上的 MLE 与表中 “$\alpha = 0$” 应区分对待。在部署或严格小样本研究中，应预先确定类别与特征词表，并明确未知值的概率处理。

A.5 附加图示

图??补充展示平滑参数的验证分数；图??展示一个树模型对不同特征的利用情况。

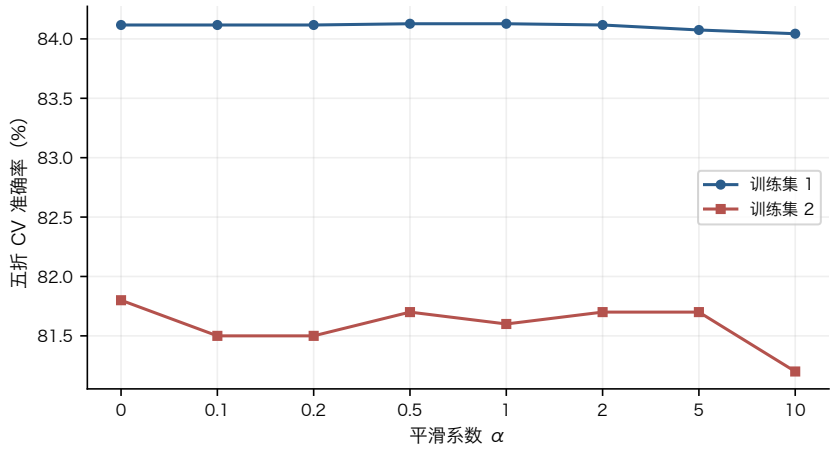


图 7 两个训练规模下平滑系数的 CV 诊断；横轴为各候选系数，按等间距显示。

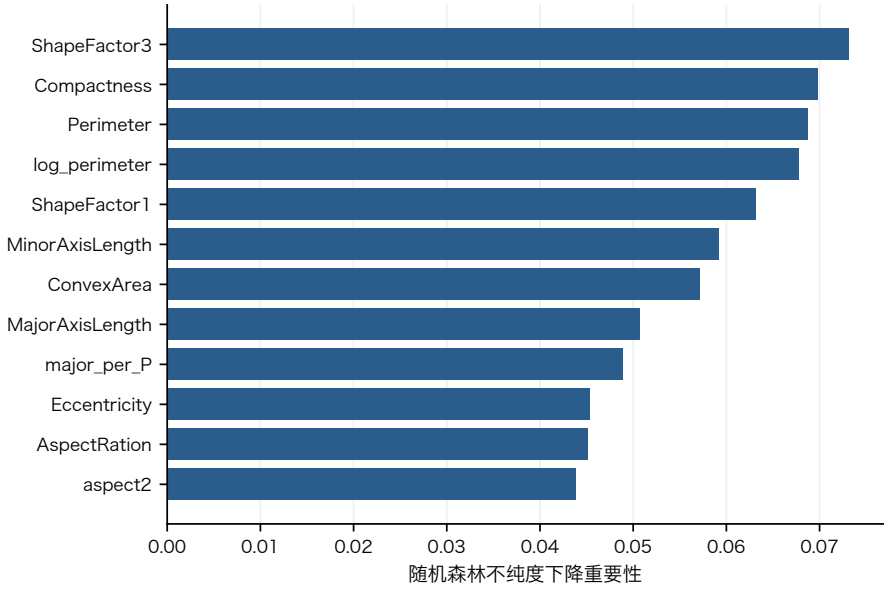


图 8 27 维随机森林的前 12 个不纯度下降重要性。该图用于辅助观察，不能解释最终 SVC 的贡献。

不纯度重要性会受相关特征分摊与特征可切分方式影响；特别是存在同义或确定性变换时，不应将图中的数值直接解读为特征的因果效应。